

USO DE INTELIGÊNCIA ARTIFICIAL PARA A CLASSIFICAÇÃO DE LESÕES DE PELE

Eduardo Antonio Giehl¹

Eduardo Lang Tessaro²

Professor Orientador: Me. Vinícius Almeida³

Resumo

A identificação precoce de lesões dermatológicas é fundamental para o diagnóstico eficaz do câncer de pele e para o aumento das chances de tratamento bem-sucedido. Com o avanço das tecnologias computacionais, métodos baseados em inteligência artificial têm se destacado como ferramentas promissoras no suporte ao diagnóstico clínico, especialmente por meio da análise automatizada de imagens dermatoscópicas, este estudo teve como propósito investigar o desempenho de modelos de aprendizado profundo aplicados à classificação automática de imagens da base HAM10000, utilizando abordagens baseadas em transferência de aprendizado. O processo metodológico envolveu etapas de pré-processamento, aplicação de técnicas de *data augmentation*, treinamento supervisionado e avaliação quantitativa dos modelos. As arquiteturas VGG16 e MobileNetV2 foram implementadas e comparadas considerando métricas como acurácia, precisão, sensibilidade, especificidade e *F1-score*, além da interpretação das matrizes de confusão para análise qualitativa dos resultados. **Palavras-chave:** Inteligência artificial; Aprendizado profundo; Diagnóstico dermatológico; Classificação de imagens; HAM10000.

¹Acadêmico do Curso de Ciência da Computação
Unoesc - Campus de São Miguel do Oeste
eduardo Antonio Giehl

²Acadêmico do Curso de Ciência da Computação
Unoesc - Campus de São Miguel do Oeste
Eduardo Lang Tessaro

³Professor do Curso de Ciência da Computação
Unoesc - Campus de São Miguel do Oeste
Vinícius Almeida

1 INTRODUÇÃO

Em um estudo mais recente, Shafin et al. (2025) propuseram a arquitetura *Sequential Triple AttentionNet (STA)*, que combina modelos pré-treinados (*ResNet* e *DenseNet*) com três mecanismos de atenção: atenção por canal, atenção suave e atenção *squeeze-and-excitation*. O modelo foi testado nas bases HAM10000 e ISIC-2018, alcançando acurácia de até 98,78%, com alto desempenho em métricas como precisão, sensibilidade e especificidade. A principal inovação foi o uso de atenção multiescala e *ensemble learning*, permitindo maior foco em regiões relevantes da imagem e redução de viés entre classes.

A dermatologia contemporânea se depara com desafios consideráveis no diagnóstico e tratamento de doenças de pele, especialmente o câncer. Para enfrentar essas dificuldades, a integração da inteligência artificial (IA) surge como uma abordagem inovadora, oferecendo novas perspectivas para a detecção precoce de câncer de pele e a classificação de alterações dérmicas, complementando a avaliação clínica realizada por profissionais de saúde (Guandalini et al., 2024).

Inicialmente, serão discutidos os fundamentos teóricos que sustentam a utilização da IA na categorização de lesões dérmicas. Compreender esses princípios é vital para perceber como técnicas modernas de aprendizado de máquina e algoritmos de reconhecimento de padrões podem ser empregados na prática médica. Estes métodos permitem um diagnóstico de enfermidades cutâneas mais exato, resultando em maior rapidez e eficácia nos diagnósticos. (Campos; Andrade; Sá, 2024).

Em seguida, será examinado a fundo o papel da IA na otimização dos diagnósticos dermatológicos. Uma análise será feita como a integração da IA com a prática médica pode contribuir para aprimorar abordagens clínicas tradicionais.

Além disso, é igualmente importante reconhecer as falhas na pesquisa atual. Identificamos os setores onde a implementação da IA na dermatologia ainda não é satisfatória e onde há potencial para avanço. Este trabalho discute questões que variam desde a diversidade dos dados até as restrições dos modelos utilizados, com o objetivo de contribuir para a formulação de soluções mais robustas e confiáveis nesse campo (Silva; Araújo; Rocha, 2023).

A incorporação das tecnologias de inteligência artificial nos sistemas de saúde é um tema crucial a ser debatido. A otimização da integração dessas tecnologias será crucial para aprimorar a categorização das lesões dérmicas. Para isso, será necessário avaliar e superar os desafios técnicos e logísticos inerentes a uma implementação bem-sucedida no ambiente clínico diário. (Oliveira; Pacheco, 2025).

Ademais, os métodos de análise e validação que são utilizados para avaliar a eficácia

da IA na análise de lesões cutâneas merecem atenção especial.

Em síntese, as bases para a análise aprofundada serão estabelecidas neste capítulo inicial, servindo como um guia que conecta discussões teóricas e práticas nas seções subsequentes. Cada uma delas irá expandir os temas discutidos aqui, contribuindo para uma compreensão mais abrangente do papel da inteligência artificial na classificação de lesões cutâneas e suas consequências mais amplas na dermatologia.

Estudos recentes reforçam a importância do uso de tecnologias de inteligência artificial na dermatologia, sobretudo em sistemas capazes de aprimorar a precisão da classificação de lesões cutâneas. Um exemplo é o trabalho de Shafin et al. (2024), que propõe um modelo baseado em redes neurais convolucionais com mecanismos de atenção, alcançando acurácia superior a 98% na base HAM10000, o que evidencia o potencial da IA na triagem automatizada de lesões.

2 DESENVOLVIMENTO

2.1 Referencial teórico

A inteligência artificial (IA) tem ocupado papel central em diversas áreas, com destaque para aplicações que envolvem reconhecimento de padrões, análise de imagens e apoio à tomada de decisão. Na saúde, técnicas de aprendizado de máquina e, mais recentemente, de aprendizado profundo (*deep learning*) têm sido empregadas para auxiliar no diagnóstico de diferentes enfermidades, incluindo o câncer de pele. Redes neurais convolucionais (CNNs) destacam-se pela capacidade de extrair automaticamente características relevantes de imagens médicas, superando, em alguns casos, o desempenho de especialistas humanos em tarefas específicas de classificação.

Diversos estudos têm explorado a aplicação de CNNs na classificação de lesões dermatológicas, muitos deles utilizando bases públicas como HAM10000 e ISIC. Pesquisas recentes demonstram que modelos pré-treinados em grandes bases de imagens naturais, como *ImageNet*, podem ser adaptados ao domínio médico por meio de transferência de aprendizado, reduzindo o tempo de treinamento e demandando menos dados anotados. Trabalhos mais recentes, como o de Shafin et al., apontam ainda para o uso de mecanismos de atenção e técnicas de ensemble, alcançando acurácias próximas ou superiores a 98% na classificação multiclases de lesões de pele, o que evidencia o potencial da IA como ferramenta de apoio na dermatologia (Torrey; Shavlik, 2010; Li et al., 2022; Shafin et al., 2024; Guandalini et al., 2024). Apesar dos avanços, a literatura também destaca desafios importantes, como o desbalanceamento entre classes, a variabilidade intraclasse e a necessidade de validação em cenários clínicos reais. Dessa forma, estudos que avaliam e comparam arquiteturas distintas de *deep learning*

continuam sendo relevantes, pois ajudam a compreender os limites e as possibilidades dos modelos, bem como a orientar futuras melhorias na área.

2.2 Materiais e métodos

Trata-se de um estudo experimental, complementado por uma revisão da literatura, com o objetivo de treinar redes neurais convolucionais (CNNs) para identificar diferentes tipos de lesões dermatológicas. A escolha do método experimental justifica-se pela necessidade de testar empiricamente modelos de aprendizado profundo em um cenário controlado, permitindo uma análise quantitativa de desempenho.

2.3 Base de Dados

A base de dados utilizada neste estudo é a HAM10000 (*Human Against Machine with 10000 training images*), amplamente reconhecida na literatura científica como referência para tarefas de classificação de lesões dermatológicas. O conjunto contém 10.015 imagens dermatoscópicas em alta resolução, no formato *JPEG*, com resolução original de 600×450 pixels, distribuídas em sete classes distintas de lesões cutâneas: *melanoma*, *nevus melanocítico*, *queratose actínica/seborreica*, *carcinoma basocelular*, *dermatofibroma*, *lesões vasculares* e *lesões benignas*.

A base HAM10000 está disponível publicamente por meio da plataforma Kaggle e foi desenvolvida em colaboração entre pesquisadores da Universidade Médica de Viena e da Universidade de Queensland, com o objetivo de fomentar avanços em aprendizado de máquina aplicado à dermatologia, como exemplificado na figura 1.

Figura 1: Exemplos de imagens

Exemplos de imagens por Classe (HAM10000)



Fonte: HAM10000

2.4 Ferramentas e Tecnologias

O desenvolvimento do modelo de inteligência artificial será realizado utilizando a linguagem de programação Python, na versão 3.x, por sua ampla adoção na área de aprendizado de máquina. As bibliotecas empregadas no projeto incluem TensorFlow e Keras, responsáveis pela construção e treinamento das redes neurais convolucionais, bem como NumPy, Pandas, Scikit-learn, Matplotlib e Seaborn, utilizadas para manipulação de dados, avaliação de métricas e geração de visualizações gráficas.

2.5 Etapas do Desenvolvimento

O desenvolvimento do modelo de classificação de lesões dermatológicas foi realizado por meio de um pipeline estruturado de aprendizado profundo, composto por três etapas principais: pré-processamento dos dados, treinamento dos modelos e avaliação de desempenho.

Na etapa de pré-processamento, todas as imagens da base HAM10000 foram padronizadas em resolução de 224x224 pixels, formato amplamente compatível com arquiteturas modernas de redes neurais convolucionais. Em seguida, os valores dos pixels foram normalizados e submetidos a funções de pré-processamento específicas de cada arquitetura utilizada. As classes foram codificadas em formato *one-hot encoding* e a divisão da base ocorreu de forma estratificada, sendo 80% destinada ao treinamento e 20% à validação, garantindo distribuição proporcional entre as classes.

A fase de treinamento contemplou o uso de duas arquiteturas pré-treinadas amplamente referenciadas na literatura: VGG16(Tabrizchi; Parvizpour; Razmara, 2023) e MobileNetV2 (Akay *et al.*, 2021), ambas aplicadas utilizando o método de *transfer learning*. Inicialmente, apenas as camadas classificadoras foram treinadas (*baseline training*). Em seguida, o pipeline foi configurado para permitir *fine-tuning*, liberando o ajuste das camadas internas previamente congeladas, com taxa de aprendizado reduzida. Para aumentar a robustez do modelo diante do desbalanceamento da base e ampliar a variabilidade das amostras, técnicas de *data augmentation* foram aplicadas, incluindo rotações, espelhamentos, zoom, deslocamentos horizontais e verticais. O número de épocas, taxa de aprendizado e o tamanho do *batch* foram definidos empiricamente, com base em experimentos iterativos realizados via execução

automatizada controlada por um menu interativo.

Por fim, na etapa de avaliação, o desempenho dos modelos foi analisado utilizando métricas amplamente aceitas em estudos de classificação de imagens médicas, incluindo acurácia, precisão, sensibilidade (*recall*), especificidade e F1-score. Além disso, foram geradas matrizes de confusão normalizadas e registradas as curvas de acurácia e perda ao longo das épocas, permitindo avaliar a convergência e estabilidade do processo de aprendizagem. O código também registrou o tempo total de treinamento de cada modelo, possibilitando a comparação entre desempenho computacional e acurácia final.

2.6 Evolução do Código e Ajustes Técnicos

Durante o desenvolvimento do projeto, o código passou por diversas revisões com o objetivo de aumentar a eficiência computacional, melhorar a organização da estrutura e permitir maior flexibilidade experimental. A primeira versão do pipeline utilizava apenas a arquitetura MobileNetV2 e continha um fluxo simplificado de treinamento, sem *callbacks* avançados ou suporte estruturado para mudanças no processo de execução. A implementação inicial consistia em um modelo estático baseado em *transfer learning* (Torrey; Shavlik, 2010), com o extrator de características congelado e apenas as camadas classificadoras sendo treinadas, conforme ilustrado a seguir:

```
base_model = MobileNetV2(weights='imagenet', include_top=False,
input_shape=(224, 224, 3))
base_model.trainable = False
x = base_model.output
predictions = Dense(train_data.num_classes, activation='softmax')(x)
model = Model(inputs=base_model.input, outputs=predictions)
```

Embora funcional, essa abordagem apresenta limitações importantes, incluindo: ausência de controle automatizado de *hardware* (GPU vs CPU), baixa flexibilidade para testes comparativos e falta de estratégias para evitar *overfitting* ou melhorar o desempenho em um *dataset* desbalanceado como a HAM10000.

Com a evolução do projeto e os experimentos realizados, o código foi reestruturado em formato modular e expandido para incluir múltiplas arquiteturas — VGG16 e MobileNetV2 — além de opções configuráveis para diferentes formas de treinamento (*baseline*, *fine-tuning*, variação de hiperparâmetros). Esse aprimoramento também incluiu a detecção automática de *hardware*, uso de *mixed precision* quando disponível, e controle dinâmico de alocação de memória da GPU, conforme demonstrado:

```
gpus = tf.config.list_physical_devices('GPU')
```

```

if gpus:
    for gpu in gpus:
        tf.config.experimental.set_memory_growth(gpu, True)
    print(f"GPUs detectadas: {gpus}")
else:
    print("Nenhuma GPU detectada. O treino será feito na CPU.")

```

Além disso, foram incorporados mecanismos automatizados como o *callback ModelCheckpoint*, garantindo que somente o melhor modelo obtido durante o treinamento fosse armazenado, e rotinas de avaliação vinculadas ao término de cada experimento, incluindo geração de matrizes de confusão normalizadas, gráficos de treinamento e exportação automática de métricas em formato JSON.

As melhorias realizadas resultaram em maior estabilidade durante o treinamento, melhor aproveitamento do *hardware* disponível e maior organização da estrutura experimental. Essa evolução metodológica refletiu diretamente no desempenho final dos modelos, permitindo análises comparativas mais consistentes e reduzindo o tempo total de interação entre experimentos

2.7 Configuração de Ambiente e Solução de Problemas

Durante as primeiras execuções do projeto em Windows 11, identificou-se que o TensorFlow não conseguia acessar a GPU disponível, fazendo com que todo o treinamento fosse executado exclusivamente em CPU. Essa limitação aumentava de forma significativa o tempo de processamento e inviabilizou a realização de experimentos mais complexos. A causa estava relacionada à incompatibilidade entre as versões do TensorFlow, CUDA, cuDNN e os drivers gráficos instalados.

Para superar o problema, iniciou-se a criação de um ambiente de desenvolvimento dedicado. Após tentativas iniciais utilizando Anaconda no Windows, optou-se pela migração para um sistema operacional Linux, visando maior compatibilidade com bibliotecas de aprendizado profundo. A instalação do Ubuntu LTS em *dual boot* proporcionou melhor integração com as versões específicas do CUDA Toolkit e do cuDNN necessárias para execução do TensorFlow com suporte a GPU.

Com o ambiente em Linux configurado, foram instalados e avaliados os seguintes componentes:

- CUDA Toolkit compatível com a versão do TensorFlow utilizada;
- cuDNN correspondente ao CUDA instalado;
- TensorFlow com suporte a GPU, validado por meio de

```
tf.config.list_physical_devices('GPU');
```

- Drivers NVIDIA adequados à *compute capability* da GPU.

Também foram aplicadas configurações adicionais no código para otimizar o uso da GPU, incluindo o ajuste de alocação dinâmica de memória com *set_memory_growth(True)* e o uso de *mixed precision training* quando suportado pela placa gráfica, após essas configurações, os modelos passaram a utilizar aceleração por *hardware* corretamente, reduzindo consideravelmente o tempo de execução por época e permitindo a realização de múltiplos experimentos comparativos. Essa etapa foi essencial para garantir um ambiente estável, reprodutível e otimizado para o treinamento dos modelos.

No ambiente definitivo, baseado em Ubuntu LTS, foram instalados Python 3.x e as principais dependências do projeto, incluindo:

- TensorFlow/Keras — para treinamento, validação e inferência;
- NumPy — para manipulação numérica;
- scikit-learn — para métricas e operações auxiliares;
- Matplotlib e Seaborn — para geração de visualizações.

Ferramentas como pip, virtualenv e Jupyter Notebook foram utilizadas no gerenciamento de dependências, modularização do código e documentação dos experimentos. A detecção e configuração da GPU foram verificadas diretamente pelo TensorFlow, assegurando seu correto funcionamento durante todo o processo de treinamento, os experimentos finais foram realizados em uma máquina dedicada ao ambiente computacional experimental, cuja configuração completa encontra-se apresentada no Quadro 1. Para o gerenciamento de dependências, modularização do código e documentação dos experimentos, foram empregadas ferramentas como pip, virtualenv e Jupyter Notebook. A GPU foi detectada e configurada diretamente pelo TensorFlow, garantindo seu correto funcionamento durante o treinamento. Os experimentos finais foram executados em uma máquina dedicada ao ambiente computacional experimental, cujos detalhes de configuração estão listados no Quadro 1.

Quadro 1 – Especificações de Hardware Utilizado nos Experimentos

COMPONENTE	ESPECIFICAÇÕES
CPU	Intel Core i7-10700F
Memória RAM	32GB DDR4

GPU	NVIDIA GeForce RTX 3050 Pegasus
VRAM	8 GB GDDR 6

Fonte: Os Autores (2025)


3 RESULTADOS

Nesta etapa são apresentados os resultados obtidos durante o treinamento e avaliação dos modelos MobileNetV2 e VGG16. A análise inclui o comportamento das curvas de acurácia e perda (*loss*), bem como o desempenho final observado por meio das matrizes de confusão normalizadas. Os resultados permitem comparar o comportamento das duas arquiteturas ao longo do processo de aprendizagem.

3.1 MobileNetV2

A Figura 2 mostra o desempenho da arquitetura MobileNetV2 durante o treinamento, destacando um progresso constante na acurácia e uma estabilidade crescente entre as épocas. O modelo obteve uma acurácia final de validação superior a 0,76, exibindo métricas gerais satisfatórias: acurácia de 0,7685, precisão ponderada de 0,763, sensibilidade ponderada de 0,7685 e *F1-score* ponderado de 0,754. Ademais, a especificidade macro alcançada foi de 0,937, com a especificidade por classe variando entre 0,720 e 1,0. Isso indica um comportamento mais consistente entre as categorias em comparação com a VGG16.


Figura 2



Fonte: Os Autores (2025).

Na Figura 3, são apresentados os valores de perda (*loss*). Verifica-se que a curva de treino diminui continuamente, enquanto a curva de validação apresentou maior oscilação, indicando possível impacto do desbalanceamento entre classes e sensibilidade do modelo a padrões mais raros

Figura 3




Fonte: Os Autores (2025).

A matriz de confusão normalizada para esse modelo encontra-se na Figura 4. A classe *melanocytic_nevi* apresentou o melhor desempenho (92,4% de acertos), o que era esperado devido à elevada representatividade no *dataset*. Em contrapartida, classes menos frequentes, como *dermatofibroma* e *vascular_lesions*, apresentaram menor precisão, refletindo a dificuldade do modelo em generalizar em condições de forte desbalanceamento.

Figura 4


Figura 5



Fonte: Os Autores (2025).

Na Figura 6, nota-se redução consistente do *loss* de treinamento, porém com maior distanciamento em relação à curva de validação, sugerindo maior tendência ao *overfitting* quando comparado à MobileNetV2.


Figura 6



Fonte: Os Autores (2025).

A Figura 7, através da matriz de confusão, evidencia as limitações já notadas no treinamento, com o melhor desempenho (96,0% de acerto) sendo novamente da classe *melanocytic_nevi*. Por outro lado, a distribuição desigual do *dataset* impactou diretamente categorias com menor representatividade, como *vascular_lesions* e *dermatofibroma*, que registraram taxas de acerto inferiores a 10%.

Figura 7



Fonte: Os Autores (2025).

3.3 Comparação e contextualização com estudos recentes

Ao comparar os resultados obtidos neste estudo com os apresentados na literatura, observa-se que o desempenho obtido pelas duas arquiteturas está alinhado com estudos semelhantes utilizando aprendizado profundo aplicado à base HAM10000. Segundo Li et al. (2022), modelos mais recentes como DenseNet, EfficientNet e variantes baseadas em mecanismos de atenção têm registrado acurácia entre 90% e 97% quando aplicados em bases como ISIC e HAM10000, superando arquiteturas clássicas como a VGG16.

Nesse sentido, o desempenho superior da MobileNetV2 em relação à VGG16, observado neste trabalho, segue a tendência descrita por Li et al. (2022), uma vez que modelos mais modernos apresentam maior capacidade de generalização e menor tendência ao *overfitting*, o Quadro 2 resume os resultados encontrados neste estudo e sua relação com dados reportados em trabalhos relevantes da área.

Quadro 2

MODEL O	BASE	Nº CLASSES	ACURÁCIA	OBS.:
MobileNetv2 (Este Estudo)	HAM10000	7	70-86%	Melhor Estabilidade
VGG16 (este estudo)	HAM10000	7	70-76%	Maior variação no validation loss
Modelos recentes (Li et al., 2022)	ISIC/HAM10000	7-10	90-97%	Envolve arquiteturas mais modernas
Inception-V3 (Li et al., 2022)	ISIC/HAM10000	7-8	~72-90%	Superou dermatologistas
DenseNet-201 (Li et al., 2022)	ISIC	8-10	90-97%	Alto desempenho em bases padronizadas
Ensembles CNN (Li et al., 2022)	ISIC 2018-2021 / HAM10000	7-10	89-97%	Melhor desempenho geral entre os modelos

Fonte: Os Autores (2025) com dados de Li et al. (2022).

Os resultados demonstram que ambas as arquiteturas foram capazes de aprender padrões relevantes para a classificação de lesões dermatológicas, ainda que com desempenho distinto entre classes. Modelos mais modernos, como a MobileNetV2, apresentaram desempenho superior à VGG16 um resultado esperado e coerente com pesquisas atuais na área de inteligência artificial aplicada à dermatologia.

4 CONCLUSÃO

Este estudo analisou o desempenho de arquiteturas de aprendizado profundo na classificação de imagens dermatoscópicas da base HAM10000. Duas redes neurais convolucionais amplamente mencionadas na literatura, VGG16 e MobileNetV2, foram implementadas e comparadas. Ambas utilizaram transferência de aprendizado e técnicas de *data augmentation* para contornar as restrições relacionadas ao tamanho e à variabilidade do conjunto de dados. As métricas quantitativas obtidas mostraram que ambas as arquiteturas conseguiram executar a tarefa de classificação de maneira satisfatória.

Em relação à VGG16, o modelo obteve uma acurácia de 0,75, uma precisão ponderada de 0,712, uma sensibilidade ponderada de 0,75 e um *F1-score* ponderado de 0,716, além de uma especificidade macro de 0,917. De acordo com as categorias da base, a especificidade por

classe variou de 0,529 a 0,998.

Para a MobileNetV2, os resultados mostraram uma acurácia de 0,7685, uma precisão ponderada de 0,763, uma sensibilidade ponderada de 0,7685 e um *F1-score* ponderado de 0,754, com uma especificidade macro de 0,937. Os valores de especificidade por classe variaram de 0,720 a 1,0.

Os resultados obtidos mostraram comportamento consistente com estudos prévios (Adebisi et al., 2024), envolvendo a base HAM10000, especialmente no que diz respeito à influência do desbalanceamento das classes e à maior dificuldade de classificação em categorias menos representadas, como *dermatofibroma* e *vascular lesions*. Embora o desempenho alcançado seja competitivo quando comparado a abordagens tradicionais, a literatura recente aponta que redes mais modernas, arquiteturas otimizadas para diagnóstico médico e modelos com mecanismos de atenção tendem a alcançar resultados superiores nesse contexto (Nie; Liu; Shen, 2022).

Dessa forma, conclui-se que o uso de transferência de aprendizado, aliado a boas práticas de pré-processamento e avaliação, constitui uma abordagem eficaz para a classificação computacional de lesões dermatológicas.

Como trabalhos futuros, recomenda-se a investigação de métodos para redução dos efeitos do desbalanceamento, como o uso de *class weights*, *oversampling*, *focal loss* ou geração sintética de imagens utilizando GANs. Além disso, sugere-se a exploração de arquiteturas mais recentes, como EfficientNet, Vision Transformers (ViT) e modelos híbridos baseados em módulos de atenção. Por fim, estudos envolvendo validação clínica, integração com fluxos médicos reais e expansão da base de dados poderão contribuir significativamente para a evolução e aplicabilidade prática deste trabalho.

USE OF ARTIFICIAL INTELLIGENCE FOR CLASSIFICATION OF SKIN LESIONS

Abstract

Early identification of dermatological lesions is essential for effective skin cancer diagnosis and for increasing the probability of successful treatment. With the advancement of computational technologies, artificial intelligence-based methods have emerged as promising

tools to support clinical decision-making, particularly through automated analysis of dermoscopic images, this study aimed to investigate the performance of deep learning models applied to automatic classification of images from the HAM10000 dataset, using transfer learning-based approaches. The methodological process included image preprocessing, data augmentation techniques, supervised training, and quantitative evaluation of the models. The VGG16 and MobileNetV2 architectures were implemented and compared using metrics such as accuracy, precision, sensitivity, specificity, and F1-score, along with confusion matrix analysis for qualitative interpretation of the results.

Keywords: Artificial intelligence; Deep learning; Dermatological diagnosis; Image classification; HAM10000.

REFERÊNCIAS

ADEBIYI, Abdulmateen et al. **Accurate skin lesion classification using multimodal learning on the ham10000 dataset.** MedRxiv, p. 2024.05.30.24308213, 2024. Disponível em: <https://www.medrxiv.org/content/10.1101/2024.05.30.24308213v5>. Acesso em: 20 fev. 2025.

AKAY, Metin et al. **Deep learning classification of systemic sclerosis skin using the MobileNetV2 model.** IEEE Open Journal of Engineering in Medicine and Biology, v. 2, p. 104-110, 2021. Disponível em: <https://ieeexplore.ieee.org/abstract/document/9380371>. Acesso em: 20 fev. 2025

BATISTA, Gustavo E. A. P. A.; PRATI, Ronaldo C.; MONARD, Maria Carolina. **A study of the behavior of several methods for balancing machine learning training data.** ACM SIGKDD Explorations Newsletter, v. 6, n. 1, p. 20-29, 2004. Disponível em: <https://dl.acm.org/doi/10.1145/1007730.1007735>. Acesso em: 20 fev. 2025.

CHAN, Stephanie et al. **Machine Learning in Dermatology: Current Applications, Opportunities, and Limitations.** Dermatol Ther (Heidelb), 2020. Disponível em: <https://link.springer.com/article/10.1007/s13555-020-00372-0>. Acesso em: 20 fev. 2025.

COELHO, Pamela de Figueiredo. **Modelos de Data Mining como serviço: interpretação de imagens.** Universidade do Minho (Portugal), ProQuest Dissertations & Theses, 2018. Disponível em: <https://www.proquest.com/openview/175fc3f409650c5041f0cc41b72fbb04/1?cbl=2026366&diss=y&pq-origsite=gscholar>. Acesso em: 10 fev. 2025.

EAPEN, Bell R. **Artificial Intelligence in Dermatology: A Practical Introduction to a Paradigm Shift.** Indian Dermatology, 2020. Disponível em: https://journals.lww.com/idoj/fulltext/2020/11060/Artificial_Intelligence_in_Dermatology_A.1.aspx. Acesso em: 22 mar. 2025.

GABARDO, Ademir Cristiano; PÉREZ, Martin. **Classificação de dados relativos a cirurgia de câncer de mama: um comparativo entre solução por redes neurais e fuzzy.** REAVI, v. 2, n. 2, 2013. Disponível em: <http://repositorio.utfpr.edu.br/jspui/handle/1/2220>. Acesso em: 10 fev. 2025.

GOLDUST, Yaser et al. COVID-19 and artificial intelligence: **Experts and dermatologists perspective.** Journal of Cosmetic Dermatology, 2022. Disponível em: <https://onlinelibrary.wiley.com/doi/full/10.1111/jocd.15310>. Acesso em: 26 fev. 2025.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning.** MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. Acesso em: 20 fev. 2025.

GUANDALINI, E.; et al. **Inteligência Artificial na Detecção de Câncer de Pele: Benefícios e Desafios para a Prática Dermatológica.** Revista REASE, v. 6, n. 1, p. e17209, 2024. Disponível em: <https://periodicorease.pro.br/rease/article/view/17209>. Acesso em: 24 fev. 2025.

JIGNESH, Chowdary G. et al. **Machine Learning and Deep Learning Methods for Building Intelligent Systems in Medicine and Drug Discovery: A Comprehensive Survey.** Cornell University, 2021. Disponível em: <https://arxiv.org/abs/2107.14037>. Acesso em: 26 fev. 2025.

JOLY-CHEVRIER, Maxine et al. **O Estado da Inteligência Artificial no Câncer de Pele. Revista de Medicina e Cirurgia Cutânea.** Disponível em:

<https://journals.sagepub.com/doi/full/10.1177/12034754241229361>. Acesso em: 28 fev. 2025.

KAWAHARA, Jeremy; HAMARNEH, Ghassan. **Visual Diagnosis of Dermatological Disorders: Human and Machine Performance.** Cornell University, 2019. Disponível em: <https://arxiv.org/abs/1906.01256>. Acesso em: 15 fev. 2025.

KRIZHEVSKY, Alex; SUTSKEVER, Ilya; HINTON, Geoffrey E. **ImageNet Classification with Deep Convolutional Neural Networks.** Communications of the ACM, v. 60, n. 6, p. 84–90, 2017. Disponível em: <https://doi.org/10.1145/3065386>. Acesso em: 20 fev. 2025.

LI, Zhouxiao et al. **Inteligência Artificial na Análise de Imagens em Dermatologia: Desenvolvimentos Atuais e Tendências Futuras.** Journal of Clinical Medicine, 2022. Disponível em: <https://www.mdpi.com/1954130>. Acesso em: 28 fev. 2025.

MANZO, Mario; PELLINO, Simone. **Bucket of Deep Transfer Learning Features and Classification Models for Melanoma Detection.** Journal of Imaging, 2020. Disponível em: <https://www.mdpi.com/903590>. Acesso em: 26 fev. 2025.

MISHRA, Sourav et al. **Assessing Robustness of Deep Learning Methods in Dermatological**

Workflow. Cornell University, 2020. Disponível em: <https://arxiv.org/abs/2001.05878>. Acesso em: 20 fev. 2025.

NARONGLERDRIT, Prasitthichai; MPORAS, Iosif. **Avaliação de Modelos CNN Baseados em Big Data na Classificação de Lesões de Pele com Melanoma.** In: KOSE, U.; ALZUBI, J. (Orgs.). *Aprendizado Profundo para Diagnóstico de Câncer*. Springer, Singapura, 2020. Disponível em: https://link.springer.com/chapter/10.1007/978-981-15-6321-8_5. Acesso em: 24 fev. 2025.

NIE, Yali et al. **A deep CNN transformer hybrid model for skin lesion classification of dermoscopic images using focal loss.** *Diagnostics*, v. 13, n. 1, p. 72, 2022. Disponível em: <https://www.mdpi.com/2032210>. Acesso em: 20 fev. 2025.

OLIVEIRA, Saulo Macedo de; PACHECO, Angelica Aparecida. **O que revelam pesquisas recentes sobre as potencialidades da IA para o ensino da Matemática?** *SciELO Preprints*, 2025. Disponível em: <https://doi.org/10.1590/SciELOPreprints.11375>. Acesso em: 13 fev. 2025.

PENNA, Letícia Machado Rodrigues; ROSCOE, Marcela Marçal. **Especialidades Médicas.** Editora Pascal, 2025. Disponível em: <https://editorapascal.com.br/wp-content/uploads/2025/01/ESPECIALIDADES-MEDICAS-1.pdf>. Acesso em: 15 fev. 2025.

REZVANTALAB, Amirreza; SAFIGHOLI, Habib; KARIMIJESHNI, Somayeh. **Dermatologist Level Dermoscopy Skin Cancer Classification Using Different Deep Learning CNN Algorithms.** Cornell University, 2018. Disponível em: <https://arxiv.org/abs/1810.10348>. Acesso em: 10 fev. 2025.

SHAFIN, Md Shafiullah et al. **Multiscale Feature Fusion Using Attention Mechanisms in Multiclass Skin Lesion Classification.** *ACM ICCA 2024*. DOI: 10.1145/3723178.3723306. Acesso em: 18 fev. 2025.

SILVA, Alexandre Luis Batista da. **Proposta de sistema assistente de diagnóstico dermatológico.** TCC — Universidade do Oeste de Santa Catarina, 2020. Disponível em: <http://hdl.handle.net/11422/13384>. Acesso em: 10 fev. 2025.

SILVA, Gabriela Cristina de Souza da; ARAÚJO, Rayssa Maria Silva; ROCHA, Willian Teixeira da. **Inteligência artificial e dermatologia.** *Anais UNIFIMES*, v. 1, n. 1, 2023. Disponível em: <https://publicacoes.unifimes.edu.br/index.php/anais-semana-universitaria/article/view/3146>. Acesso em: 13 fev. 2025.

SONNTAG, Daniel; NUNNARI, Fabrizio; PROFITLICH, Hans-Jurgen. **The Skincare Project: An Interactive Deep Learning System for Differential Diagnosis of Malignant Skin Lesions.** Cornell University, 2020. Disponível em: <https://arxiv.org/abs/2005.09448>. Acesso em: 24 fev. 2025.

TABRIZCHI, Hamed; PARVIZPOUR, Sepideh; RAZMARA, Jafar. **An improved VGG model for skin cancer detection.** *Neural Processing Letters*, v. 55, n. 4, p. 3715-3732, 2023. Disponível em: <https://link.springer.com/article/10.1007/s11063-022-10927-1>.

TORREY, Lisa; SHAVLIK, Jude. **Transfer learning.** In: *Handbook of Research on Machine Learning Applications and Trends*. IGI Global Scientific Publishing, 2010. Disponível em: https://books.google.com.br/books?id=gFpKXO8H_6YC.

TSCHANDL, Philipp. **The HAM10000 Dataset.** Harvard Dataverse, 2018. Disponível em: <https://doi.org/10.7910/DVN/DBW86T>. Acesso em: 24 fev. 2025.